

现代信号处理 2025 Fall - 第二次 Project

项目概览

本次项目的目标是对房颤（Atrial Fibrillation, AF）和非房颤心电图（ECG）信号进行分类，任务分为两部分：

- **任务 1：**使用深度学习方法对原始心电图数据进行分类。
- **任务 2：**构建并微调一个基于大语言模型的多模态分类器，并与任务 1 的基线进行对比。

代码及要求

本项目提供了任务 1 的大部分代码，包括数据预处理和模型训练部分。任务 2 将基于任务 1 的 CNN 模型作为编码器，构建多模态指令微调数据集，并采用 LoRA 对大语言模型进行微调。报告请使用提供的 LaTeX 模板，并按照 IEEE 格式撰写报告。具体要求如下：

任务 1：深度学习对原始数据进行分类

子任务 1.1：数据预处理与可视化

- 目标：理解并实现数据预处理部分。
- 要求：
 - ✧ 加载心电图数据。
 - ✧ 可视化原始数据，如绘制 ECG 信号的时频域图。

子任务 1.2：模型构建与训练

- 目标：完成深度学习模型的构建和训练。
- 要求：
 - ✧ 提供的代码仅实现了[原论文](#)的 stream 1，根据论文实现完整网络框架（stream 1 + stream 2）。
 - ✧ 量化 stream 2 对模型性能的影响。

子任务 1.3：模型评估与性能对比

- 目标：评估模型并与其他基准方法进行比较。
- 要求：
 - ✧ 计算模型在测试集上的性能。
 - ✧ 绘制 ROC 曲线，并计算 AUC 值。

子任务 1.4：超参数调优与优化

- 目标：优化模型性能。

- 要求：
 - ✧ 对模型的超参数进行调整，例如学习率、批大小、卷积核大小等。
 - ✧ 评估不同超参数配置的模型性能并记录结果。

子任务 1.5: 数据增强与实验

- 目标：实现并测试不同的数据增强方法。
- 要求：
 - ✧ 在数据加载器中增加新的数据增强方法（如加入噪声、随机时间尺度放缩等）。
 - ✧ 实验不同的数据增强策略，并分析它们对模型训练和测试结果的影响。
 - ✧ 可视化增强后的数据，帮助理解增强策略如何改变数据。

任务 2: 基于 LLM 的多模态指令微调

子任务 2.1: 多模态指令数据集构建

- 目标：构建用于指令微调的多模态数据集。
- 要求：
 - ✧ 将 ECG 数据和房颤标签转换为“指令-答案”对。
 - ✧ 数据集应包含 ECG 信号特征向量、指令文本（“请判断<这个 ECG 信号>是否有房颤？”）和答案文本（“有房颤。”或“无房颤。”）。

子任务 2.2: 多模态模型搭建

- 目标：整合 CNN、投影层和 LLM，搭建多模态模型。
- 要求：
 - ✧ 加载并冻结在任务 1 中训练好的 CNN 模型，用于将 ECG 信号转换为高维特征向量。
 - ✧ 实现一个全连接神经网络，将 CNN 特征向量的维度映射到 LLM 的文本嵌入维度一致。
 - ✧ 选用一个开源 LLM（如 Qwen-7B）作为模型核心。

子任务 2.3: 模型参数高效微调

- 目标：使用 LoRA 策略对模型进行指令微调。
- 要求：
 - ✧ 采用 PEFT（参数高效微调）策略，如 LoRA。
 - ✧ 实现训练逻辑，将投影后的 ECG 向量与指令文本的嵌入向量进行拼接，作为 LLM 的输入，训练 LLM 预测答案文本。

子任务 2.4: 评估与对比

- 目标：评估 LLM 模型的分类性能，并与任务 1 的 CNN 基线对比。
- 要求：
 - ✧ 将 LLM 的输出文本（如“有房颤。”/“无房颤。”）解析回“1/0”标签。

- ✧ 计算准确率、F1-score 等指标，与任务 1 的 CNN 基线模型进行对比。

可选任务：思考与讨论

- 目标：深入分析多模态 LLM 方法的特性。
- 要求：
 - ✧ 与传统 CNN 分类器（任务 1）相比，这种基于 LLM 的方法（任务 2）的主要优势和劣势是什么？
 - ✧ 在这个任务中，CNN 编码器的作用是什么？是否可以尝试不同的编码器？
 - ✧ 指令的措辞（例如，"是否有房颤？" vs. "此心电图是否显示心房颤动？"）是否会影响模型性能？为什么？
 - ✧ 如果希望模型不仅能判断"有/无"，还能给出置信度（例如，"很有可能有房颤"），应该如何修改训练数据和方法？